

連合学習を用いたグラフニューラルネットワークの性能評価

Performance Evaluation of Federated Graph Neural Networks

寺田隼¹
Shun Terada

江易翰¹
Yi-Han Chiang

林海¹
Hai Lin

計宇生²
Yusheng Ji

大阪公立大学¹
Osaka Metropolitan University

国立情報学研究所²
National Institute of Informatics

1 まえがき

グラフニューラルネットワーク (GNN) の研究は、グラフ構造化データから分散表現を学習できる能力により急速に発展しているが、大量のグラフデータを中央集約して GNN を訓練することは、プライバシーの懸念等により困難である。そのため、分散データ環境におけるプライバシー保護型の学習フレームワークとして連合学習が注目されている。本研究では、モデルにグラフ畳み込みニューラルネットワーク (GCN) を採用した連合学習において、クライアント数による性能比較を行う。

2 システムモデル

本研究では、従来の連合学習アルゴリズムである FedAvg[1] を採用し、パラメータサーバ、 K 台のクライアントから構成されるネットワークを考える。 $\tilde{\mathbf{A}}$ は隣接行列、 $\tilde{\mathbf{D}}$ は次数行列、 $\mathbf{H}^{(l)}$ は l 層目のノード埋め込み行列、 $\mathbf{W}^{(l)}$ は l 層目のモデルパラメータ行列を表す。ただし、 $\mathbf{H}^{(0)}$ は入力した特徴量である。更に、 $\mathbf{w}_k^{(t,e)}$ はグローバルラウンド t 、ローカルラウンド $e \leq E$ におけるクライアント k のモデルパラメータ、 $\mathcal{G}_k = (\mathcal{V}, \mathcal{E})$ はクライアント k の持つサブグラフを表す。ここで、 $\mathcal{V}$ 、 $\mathcal{E}$ はそれぞれノード集合とエッジ集合を表す。システムモデルは以下の (a)~(c) の 3 段階で繰り返し行われる。

- グローバルモデルの配布：サーバがグローバルモデル $\tilde{\mathbf{w}}^{(t)}$ を各クライアントへ配布する。
- ローカル訓練： σ を非線形な ReLU 関数としたとき、伝搬式 $\mathbf{H}^{(l+1)} = \sigma \left(\tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}} \mathbf{H}^{(l)} \mathbf{W}^{(l)} \right)$ によってノードの特徴量を隣接行列によって重みづけしていく。その後、勾配を $\mathbf{g}_k^{(t,e)} = \nabla f(\mathbf{w}_k^{(t,e-1)}, \mathbf{H}^{(2)}, \mathbf{Y}_k)$ で求める。ただし、 $f(\cdot)$ はクライアントクロスエントロピー関数、 $\mathbf{Y}_k$ はクライアント k が持つ正解ラベルである。モデルのパラメータは $\mathbf{w}_k^{(t,e)} = \mathbf{w}_k^{(t,e-1)} - \eta \mathbf{g}_k^{(t,e)}$ で更新される。ただし、 $\mathbf{w}_k^{(t,0)} = \tilde{\mathbf{w}}^{(t)}$ とする。
- 集約して平均化：各クライアントがサーバにパラメータ $\mathbf{w}_k^{(t,E)}$ を送信し、サーバは集約して $\tilde{\mathbf{w}}^{(t+1)} = \frac{1}{K} \sum_{k=1}^K \mathbf{w}_k^{(t,E)}$ のように平均化を行う。

3 シミュレーション

実験では、ノードを論文、エッジを論文の引用関係を表す Cora データセット [2] を、特徴量の近いノードごとにクラスタリングする K-means 法によってサブグラフを作成し、各クライアントに振り分けた。比較手法として、




図 1 シミュレーション結果

データを中央に集約して行う中央集権型と、通信を行わずに各クライアントが独自で訓練を行う LocGNN を用いる。2 層 GCN, Adam オプティマイザ ($\eta = 0.005$), イテレーション数 50 で学習する。

図 1 はラウンドごとの正解率を示す。LocGNN は各クライアントが保持するデータ量に応じた加重平均である。中央集権型が最も精度が高く、クライアント数が増えるほど精度が下がることがわかる。これはクライアント間のノードをつなぐエッジの数がクライアント数の増加とともに増え、失われる近傍情報も増加するためである。また、同じクライアント数のとき FedGNN が LocGNN より精度が高い。これはクライアント間で情報をうまく統合できているためである。このことから、クライアントが協調的に訓練を行う有効性が示される。

4 結論

本研究では、グラフデータを用いた連合学習における性能評価を行った。クライアント数が増えるほど精度が落ちることと、FedGNN が LocGNN に比べて精度において高い性能を示すことが分かった。

謝辞

本研究は JSPS 科研費 JP23K16871 と JP24K02937, 国立情報学研究所公募型共同研究 251S5-22661 及び公益財団法人大川情報通信基金の助成を受けたものです。

参考文献

- [1] H. B. McMahan *et al.*, “Communication-efficient learning of deep networks from decentralized data,” in *Proc. AISTATS*, Apr. 2017.
- [2] P. Sen *et al.*, “Collective classification in network data,” *AI Mag.*, vol. 29, no. 3, p. 93, Sept. 2008.