

グラフニューラルネットワーク を用いた連合学習



Gr.6 知的情報通信研究室

寺田 隼

目次

1. 連合学習
2. グラフデータ
3. Graph Neural Network (GNN)
4. Graph Convolutinal Network (GCN)
5. システムモデル
6. データセット
7. シミュレーション設定
8. 結果
9. 結論と今後の課題

1. 連合学習




連合学習は**プライバシー保護**の点で優れている

B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y. Arcas, "Communication-Efficient Learning of Deep Networks from Decentralized Data," in *Artificial Intelligence and Statistics*. PMLR, Apr 2017, pp. 1273–1282.

2. グラフデータ

グラフの例：路線図（電車のネットワーク）



■ グラフの構成要素

- ・ 駅： ノード 
- ・ 線路： エッジ 

■ 例


『B駅』と『C駅』が線路でつながっている状態



グラフでは，ノード間にエッジがある（**接続関係**がある）と表現する

3. Graph Neural Network (GNN)

例 論文の引用関係




■ グラフの構成要素

- ・ ノード 論文
- ・ エッジ 引用関係

■ GNNのタスク


論文のカテゴリ分類

- ・ 化学 (chemistry)
- ・ 工学 (Engineering)



3. Graph Neural Network (GNN)

モデル訓練時: メッセージパッシング



$h_n^{(l)}$ $\equiv$ ノード n の l 層目の特徴量

・ 隣の情報（特徴量）を集約

・ 集約した情報をもとに自身の特徴量を更新


メッセージパッシングと誤差逆伝搬を繰り返してモデルを訓練




1層目：隣の情報を集約
2層目：2つ隣の情報を集約

3. Graph Neural Network (GNN)

テストの流れ



データ
の入力



訓練後の
モデル



判定

予測対象



工学

4. グラフ畳み込みニューラルネットワーク


Graph Convolutional Network (GCN) … GNNのメッセージパッシングに以下の伝搬式を使用

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right)$$

- $\tilde{A} : A + I$ (隣接行列 + 単位行列)
- $\tilde{D}^{-\frac{1}{2}}$: 次数行列 D の正規化表現
- $H^{(l)}$: l 層目のノードの特徴量行列
- $W^{(l)}$: l 層目のモデルパラメータ

- σ : 非線形関数 (ReLU)

$$f(x) = \max(0, x)$$



• つながり (エッジ) が**多い**
→ 影響力 **大**

• つながり (エッジ) が**少ない**
→ 影響力 **小**




正規化

影響力の偏りを小さくする

Thomas N. Kipf, Max Welling, "Semi-Supervised Classification with Graph Convolutional Network,"
in *arXiv preprint arXiv: 1609.02907*, Feb 2017.

4. グラフ畳み込みニューラルネットワーク



隣接行列 A :

$$\begin{matrix} & \begin{matrix} 1 & 2 & 3 \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \end{matrix} & \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \end{matrix}$$

次数行列 D :

$$\begin{matrix} & \begin{matrix} 1 & 2 & 3 \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \end{matrix} & \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 2 \end{bmatrix} \end{matrix}$$

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right)$$

正規化隣接行列
(グラフ構造)

$$\tilde{A} \tilde{D}^{-\frac{1}{2}} \tilde{A}$$


初期特徴量 $H^{(0)}$
(ノード属性)

$$\begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

重み行列 $W^{(1)}$
(モデルパラメータ)

$$\begin{bmatrix} W_{11} & W_{12} \\ W_{21} & W_{22} \\ W_{31} & W_{33} \end{bmatrix}$$

ReLU活性化関数




特徴量 $H^{(1)}$

$$\begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix}$$

$$\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(0)} W^{(0)}$$

5. システムモデル

FedGNN: 連合学習 + GNN



① グローバルモデルの配布

② GCNの伝搬式に従ってローカルモデルの訓練


③ ローカルモデルの集約

④ モデルの平均化

6. データセット

Cora … 論文の引用関係を集めたデータセット

- ・ ノード数： 2708
- ・ エッジ数： 5429 (方向なし)
- ・ クラス数： 7 (論文のジャンル)
- ・ 特徴量： 特定の1433種類のワードが含まれているかを0/1値で表す



Prithviraj Sen, Galileo Namata, Mustafa Bilgic, Lise Getoor, Brian Galligher, and Tina Eliassi-Rad.
Collective classification in network data. AI magazine, 29(3):93, 2008.

7. シミュレーション設定

パラメータ設定

項目	パラメータ
モデル	GCN
データセット	Cora（論文ネットワーク）
クライアント数	5, 10, 20
データ分割方法	K-means
最適化手法	Adam(学習率: 0.005)
ラウンド数	50
イテレーション数	30


7. シミュレーション設定

比較手法

- ①中央集権型 (Centralized)
 - ・データを一か所に集める (理論値)
- ②連合学習 × GNN (FedGNN)
- ③ローカル訓練 (LocGNN)
 - ・モデルを集約せず、各クライアントが独自でモデルの訓練を行う

8. シミュレーション結果

GCNの層数：2層、クライアント数: $K = 5, 10, 20$ を比較




- ・クライアント数が増加するにつれ、テスト精度が減少する

- ・同一クライアント数の場合、テスト精度は
中央集権型 > FedGNN > LocGNN

8. シミュレーション結果

GCN層数を1～10で変化



- 層数2のときが最も精度が高い
- 3層以降、層数を増やすと精度が落ちていく

9. 結論と今後の課題

結論

- グラフデータを用いた連合学習において、クライアント数比較による **モデルの性能評価** を行った
- クライアント数が増加するとともに、 **テスト精度が下がる** ことが確認された.
- 中央集権型 > FedGNN > LocGNNの順に **テスト精度が高い** ことが確認された.

今後の課題

- クライアント数を増やしてモデル精度が下がらない手法を考える

ご清聴ありがとうございました