

連合学習を用いたグラフニューラルネットワークの性能評価

Gr. 6 寺田隼

1 序論

グラフニューラルネットワーク (GNN) の研究は、グラフ構造化データから分散表現を学習できる能力により急速に発展しているが、大量のグラフデータを中央集約して GNN を訓練することは、プライバシーの懸念等により困難である。そのため、分散データ環境におけるプライバシー保護型の学習フレームワークとして連合学習が注目されている。本研究では、ローカルモデルにグラフ畳み込みニューラルネットワーク (GCN) を採用した連合学習において、クライアント数による性能比較を行う。

2 システムモデル

本研究では、従来の連合学習アルゴリズムである FedAvg[1] を採用し、パラメータサーバ、 K 台のクライアントから構成されるネットワークを考える。 $\hat{A}$ は隣接行列、 $\hat{D}$ は次数行列、 $H^{(l)}$ は l は層目のノード埋め込み行列、 $W^{(l)}$ は l 層目のモデルパラメータ行列を表す。ただし、 $H^{(0)}$ は入力した特徴量である。更に、 $w_k^{(t,e)}$ はグローバルラウンド t 、ローカルラウンド $e \leq E$ におけるクライアント k のモデルパラメータ、 $G_k = (V, E)$ はクライアント k の持つサブグラフを表す。ここで、 V 、 E はそれぞれノード集合とエッジ集合を表す。システムモデルは以下の (a)~(c) の 3 段階で繰り返し行われる。

- グローバルモデルの配布**：サーバがグローバルモデル $\tilde{w}^{(t)}$ を各クライアントへ配布する。
- ローカル訓練**： σ を非線形な ReLU 関数としたとき、伝搬式 $H^{(l+1)} = \sigma(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} H^{(l)} W^{(l)})$ によってノードの特徴量を隣接行列によって重みづけしていく。その後、勾配を $g_k^{(t,e)} = \nabla f(w_k^{(t,e-1)}, H^{(2)}, Y_k)$ で求める。ただし、 $f(\cdot)$ はクライアントクロスエントロピー関数、 Y_k はクライアント k が持つ正解ラベルである。モデルのパラメータは $w_k^{(t,e)} = w_k^{(t,e-1)} - \eta g_k^{(t,e)}$ で更新される。ただし、 $w_k^{(t,0)} = \tilde{w}^{(t)}$ とする。
- 集約して平均化**：各クライアントがサーバにパラメータ $w_k^{(t,E)}$ を送信し、サーバは集約して $\tilde{w}^{(t+1)} = \frac{1}{K} \sum_{k=1}^K w_k^{(t,E)}$ のように平均化を行う。

3 シミュレーション

実験では、ノードを論文、エッジを論文の引用関係を表す小規模なグラフデータセットである Cora[2] を用いた。Cora データセットはノード数:2708、エッジ数:5429 で、各特徴量は特定の単語が含まれるかの 0/1 でクラスタであり、1433 次元で表され、K-means 法によってサブグラフを作成し、各クライアントに振り分けた。K-means 法は、データを K 個のクラスタに




図 1: シミュレーション結果

分割し、各クラスタ内のデータの特徴量の類似性を最大化するクラスタリング手法である。K-means 法分割法はグラフのトポロジを考慮しないため、異なるクライアントが所持するサブグラフ間での接続が多くなり、結果として、各クライアントが独立して訓練を行う場合と比べ、全クライアントが協調して訓練を行う連合学習のモデル精度が高くなると予想される。

比較手法として、データを中央に集約して行う中央集権型と、通信を行わずに各クライアントが独自で訓練を行う LocGNN を用いる。2 層 GCN, Adam オプティマイザ ($\eta = 0.005$)、イテレーション数 50 で学習する。図 1 はラウンドごとの正解率を示す。LocGNN は各クライアントが保持するデータ量に応じた加重平均である。中央集権型が最も精度が高く、クライアント数が増えるほど精度が下がることがわかる。これはクライアント間のノードをつなぐエッジの数がクライアント数の増加とともに増え、失われる近傍情報も増加するためである。また、同じクライアント数のとき FedGNN が LocGNN より精度が高い。これはクライアント間で情報をうまく統合できているためである。このことから、クライアントが協調的に訓練を行う有効性が示される。

4 結論

本研究では、グラフデータを用いた連合学習における性能評価を行った。クライアント数が増えるほど精度が落ちることと、FedGNN が LocGNN に比べて精度において高い性能を示し、グラフデータにおける連合学習の有効性が示された。

参考文献

- [1] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y. Arcas, "Communication-efficient learning of deep networks from decentralized data," in *Proc. AISTATS*, Apr. 2017, pp. 1273–1282.
- [2] P. Sen et al., "Collective classification in network data," *AI Mag.*, vol. 29, no. 3, p. 93, Sept. 2008.